Sistema de classificació visual d'estils d'indumentària

Pràctica Extra
Intel·ligència Artificial

Aila Romaguera Mezquida

Universitat de les Illes Balears

Curs 2025-2026

Índex

1 Definició i Justificació del Problema **3**
1.1 Introducció . . . 3
1.2 Descripció del Problema . . . 3
1.3 Justificació i Aplicacions . . . 3

2 Dataset: Captura i Preparació de Dades **5**
2.1 Fonts de Dades . . . 5
2.2 Distribució del Dataset . . . 5
2.3 Estratègia de Captura i Varietat Visual . . . 5
2.4 Exemples del Dataset . . . 5

3 Entrenament i Ajust d'Hiperparàmetres **7**
3.1 Configuració dels entrenaments i resultats . . . 7
3.2 Justificació dels Hiperparàmetres Escollits . . . 7

4 Anàlisi de Resultats i Mètriques **8**
4.1 Mètriques d'Avaluació . . . 8
4.2 Mètriques d'Avaluació . . . 8
4.3 Matriu de Confusió . . . 8
4.4 Captura de Teachable Machine . . . 9

5 Discussió de Biaixos i Errors **10**
5.1 Anàlisi d'Errors . . . 10
5.2 Biaixos del Dataset . . . 10
5.3 Propostes de Millora . . . 11

6 Implementació de l'Aplicació **12**
6.1 Descripció Tècnica . . . 12
6.2 Llindar de Confiança . . . 12

7 Conclusions **13**

1 Definició i Justificació del Problema

1.1 Introducció

L'objectiu d'aquesta pràctica és demostrar l'utilitat de l'eina Teachable Machine i la seva integració en una aplicació útil. El tema central escollit és la diferenciació entre estètiques de vestimenta que es poden observar a les xarxes socials, una creixent moda en les darreres generacions, i d'interès especial per campanyes de marques de roba i estudi de mercat. Es poden trobar nombroses categories però per l'abast d'aquest treball s'han distingit 4 estils de moda ben diferenciats.

Llavors, en les següents pàgines, es documenta el flux de treball des de l'entrenament del model fins a l'obtenció de l'aplicació classificadora d'estils, on mitjançant la pujada d'una imatge o l'utilització de la càmara webcam serà capaç de categoritzar la imatge en una de les classes definides.

1.2 Descripció del Problema

S'han definit quatre estils que tenen característiques visuals distintives: paleta cromàtica, silueta, textures i patrons; i que conformen 4 estils populars a plataformes de xarxes socials com TikTok, Instagram i Pinterest.
Les classes definides són:

- **Old Money**: Estètica elegant i minimalista inspirada en l'aristocràcia tradicional. Predominen colors neutres (beix, blanc, blau marí), teixits d'alta qualitat i siluetes clàssiques sense logos visibles.
- **Streetwear**: Moda urbana caracteritzada per peces esportives, samarretes àmplies, sabatilles i estampats cridaners. Incorpora freqüentment logos de marques i influències del hip-hop i el skate.
- **CottageCore**: Estil romàntic i nostàlgic que evoca la vida rural. Destaquen els vestits fluids, estampats florals, teixits naturals com el lli, i una paleta de colors suaus i terrosos.
- **Rockstar**: Estètica rebel associada a la música rock. Es caracteritza per l'ús de cuir, colors foscos (negre predominant), accessoris metàl·lics, samarretes de bandes i textures desgastades.

Els termes utilitzats per identificar aquestes classes s'han decidit a partir dels *hashtags* o denominacions populars a les xarxes socials. Per tant, s'ha de tenir en consideració que aquests termes són canviants per la pròpia naturalesa del cicle de les modes a internet i la seva ràpida evolució. Això pot causar que encara que ara mateix siguin termes actuals, en un període de temps curt podrien tornar-se "anticuats". Així i tot, s'ha decidit mantenir així per la facilitat de comprensió per les persones que es troben en aquest subgènere de les xarxes socials.

1.3 Justificació i Aplicacions

La classificació automàtica d'estils de moda té múltiples aplicacions en l'àmbit comercial i tecnològic:

- **Sistemes de recomanació**: Personalització de suggeriments de productes en plataformes d'e-commerce basant-se en l'estil preferit de l'usuari.
- **Cerca visual**: Permetre als usuaris cercar productes similars a un estil concret pujant una imatge de referència.

- **Segmentació de clients**: Classificació automàtica de clients segons les seves preferències estètiques per campanyes de màrqueting personalitzades.
- **Anàlisi de tendències**: Detecció automàtica de tendències de moda mitjançant l'anàlisi d'imatges de xarxes socials.

2 Dataset: Captura i Preparació de Dades

2.1 Fonts de Dades

Les imatges del dataset s'han obtingut de Pinterest de manera manual.

2.2 Distribució del Dataset

El dataset s'ha dividit en conjunts d'entrenament i test per avaluar la capacitat de generalització del model:

Classe	**Train**	**Test**
Old Money	80	15
Streetwear	80	15
CottageCore	80	15
Rockstar	80	15
Total	320	60

Taula 1: Distribució del dataset per classe i conjunt.

2.3 Estratègia de Captura i Varietat Visual

Per evitar l'*overfitting* a característiques irrellevants, s'ha assegurat que les imatges de cada classe tinguin varietat en:

- **Fons**: Interiors, exteriors, estudis fotogràfics, carrers urbans
- **Il·luminació**: Llum natural, artificial, diferents hores del dia
- **Subjectes**: Diversitat de gènere, edat i tipus de cos
- **Angles**: Fotos frontals, de cos sencer, detalls de roba

2.4 Exemples del Dataset

Figura 1: Exemples d'estil Old Money

Figura 2: Exemples d'estil Streetwear

Figura 3: Exemples d'estil CottageCore

Figura 4: Exemples d'estil Rockstar

3 Entrenament i Ajust d'Hiperparàmetres

3.1 Configuració dels entrenaments i resultats

La mida del batch size s'ha mantingut constant a 16. S'han provat diverses configuracions dels altres hiperparàmetres per optimitzar el rendiment del model:

Experiment	**Èpoques**	η	**Accuracy**
1	50	0.001	0.95
2	100	0.001	0.98
3	50	0.0001	0.93
4	100	0.0001	0.98

Taula 2: Resultats d'accuracy pels diferents hiperparàmetres

3.2 Justificació dels Hiperparàmetres Escollits

Configuració final seleccionada:
Els experiments 1 i 3 han tingut el mateix resultat: només un error i una accuracy, per tant, del 98%. Llavors s'ha escollit el model de l'experiment 2, amb 100 èpoques i learning rate de 0.001, ja que aconsegueix el mateix resultat amb una convergència més ràpida.

- **Èpoques (100)**: Permet una convergència completa del model sense risc significatiu de sobreajust, donat el tamany reduït del dataset.
- **Taxa d'aprenentatge (0.001)**: Valor estàndard que ofereix un bon equilibri entre velocitat de convergència i estabilitat. Un valor menor (0.0001) no va millorar els resultats però va ralentir l'entrenament.

Enllaç al model entrenat: https://teachablemachine.withgoogle.com/models/bMXg8u3wX/

4 Anàlisi de Resultats i Mètriques

4.1 Mètriques d'Avaluació

4.2 Mètriques d'Avaluació

L'avaluació del model s'ha realitzat mitjançant les mètriques estàndard de classificació: accuracy, precision, recall i F1-score.

Accuracy global:

$$\text{Accuracy} = \frac{TP_{total}}{N} = \frac{15 + 15 + 14 + 15}{60} = \frac{59}{60} \approx 0.983$$

Mètriques per classe:
Per a cada classe c, es calculen:

$$\text{Precision}_c = \frac{TP_c}{TP_c + FP_c} \quad \text{Recall}_c = \frac{TP_c}{TP_c + FN_c} \quad \text{F1}_c = 2 \cdot \frac{\text{Precision}_c \cdot \text{Recall}_c}{\text{Precision}_c + \text{Recall}_c}$$

Classe	**TP**	**FP**	**FN**	**Precision**	**Recall**	**F1**
Old Money	15	1	0	0.94	1.00	0.97
Streetwear	15	0	0	1.00	1.00	1.00
CottageCore	14	0	1	1.00	0.93	0.96
Rockstar	15	0	0	1.00	1.00	1.00
Macro Avg				0.98	0.98	0.98

Taula 3: Mètriques d'avaluació per classe sobre el conjunt de test.

El model presenta un rendiment excel·lent amb un F1-score macro de 0.98. L'única confusió detectada és entre CottageCore i Old Money, on una imatge CottageCore ha estat classificada erròniament com Old Money, reduint el recall d'aquesta classe a 0.93.

4.3 Matriu de Confusió

	OldMoney	**Streetwear**	**CottageCore**	**Rockstar**
OldMoney	15	0	0	0
Streetwear	0	15	0	0
CottageCore	1	0	14	0
Rockstar	0	0	0	15

Taula 4: Matriu de confusió sobre el conjunt de test.

4.4 Captura de Teachable Machine

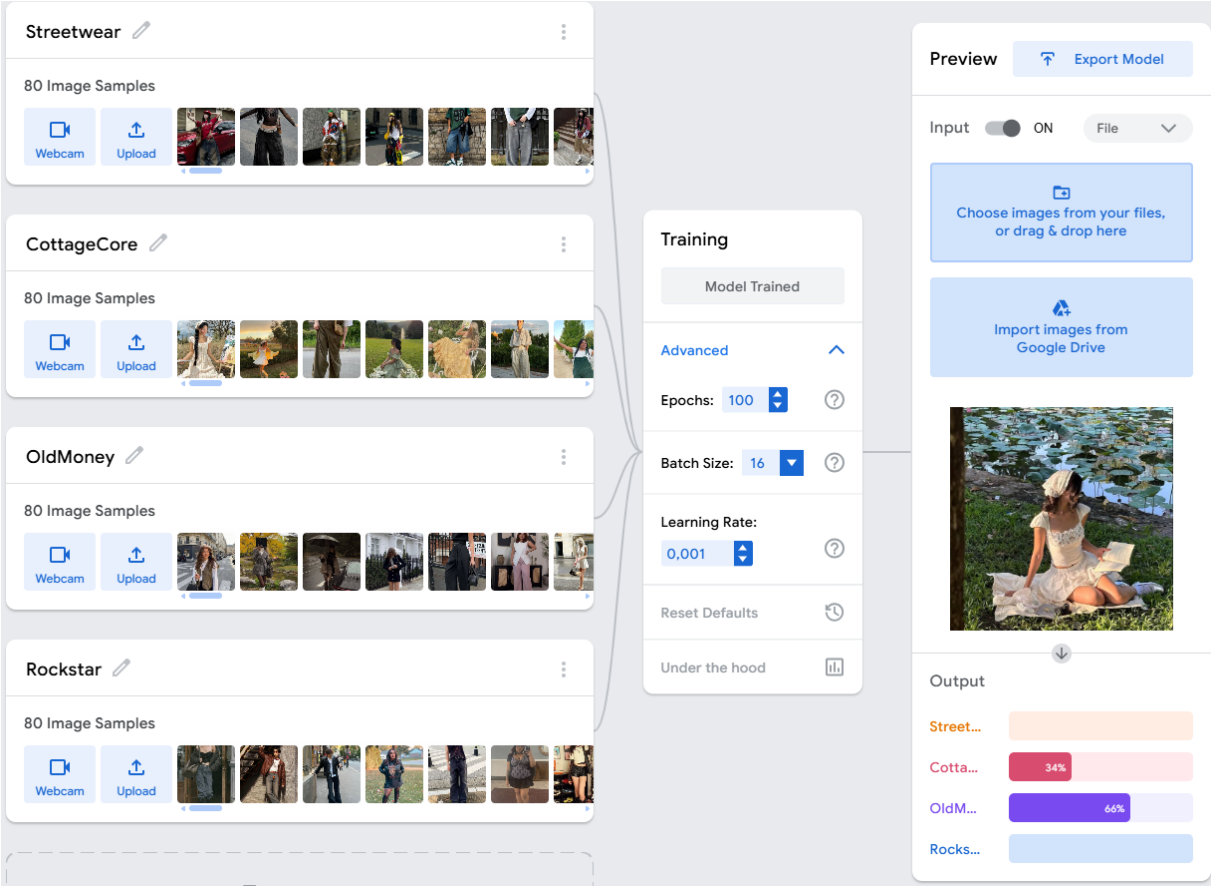

Figura 5: Error en classificació de classe CottageCore

Descripció de la imatge

En aquesta imatge es pot veure l'error que comet el model òptim, on es confón la classe CottageCore (amb una predicció del 34%), amb la classe OldMoney (amb predicció del 66%). En ella es pot visualitzar una al·lota amb vestimenta d'estil romàntic i sensible, asseguda en un entorn natural. Els colors encaixen amb ambdues estètiques (clars, naturals), manca dels estampats característics del primer estil i tendeix al minimalisme. Totes aquestes raons poden haver confós al model, que hauria d'haver captat característiques definitòries com la textura de la roba (arrugada i rústica).

5 Discussió de Biaixos i Errors

5.1 Anàlisi d'Errors

S'han identificat els següents patrons d'error:

- **Confusió entre CottageCore i OldMoney**: Aquestes dues classes ja d'inici presenten característiques similars que les pot confondre fins i tot per a l'ull humà. Es basen en una estètica més conservadora, i amb colors més tènues. La principal diferència és l'ús d'estampats i el component rústic que presenta la classe CottageCore, mentre que l'altra es manté més sòbria, i encara que no hi ha absència d'estampats, aquests són més estructurats i "nets". Llavors quan una vestimenta CottageCore no presenta un estampat més exagerat o una rusticitat característica, es transforma en més indetectable, ja que la diferència resideix en la textura del teixit i l'essència romàntica.

- **Sensibilitat a la il·luminació:** Imatges amb il·luminació deficient o contrallum dificulten la classificació, ja que els colors i textures (característiques clau per distingir estils) es perceben de manera diferent. Això és especialment problemàtic per distingir Old Money de CottageCore, on la paleta cromàtica és similar.

- **Influència del fons**: ha estat complicat trobar imatges amb la mateixa varietat de fons per a totes les classes. Això és degut al fet que, com són imatges çurades"de Pinterest, l'ubicació de la fotografia va en consonància amb l'estil de roba. Per aquesta raó els fons de les imatges de CottageCore i OldMoney són més a espais naturals o amb colors clars. La classe Rockstar sol ubicar-se en terrenys urbans, concerts i més de nit. La classe Streetwear sol ser més *selfies*, ambients urbans i amb colors saturats.

5.2 Biaixos del Dataset

Possibles biaixos identificats:

- **Biaix de gènere**: La majoria d'imatges del conjunt de train són dones ja que són les principals participants en aquestes tendències estílistiques. Llavors la proporció d'imatges és d'1 home per cada 8 dones (cada dataset conté aproximadament 10 homes).

- **Biaix geogràfic i racial:** Les imatges s'han recopilat des d'IPs espanyoles, per tant l'algoritme de recomanació de Pinterest està enfocat a audiències occidentals. S'ha intentat introduir varietat racial, però existeix una sobrerepresentació de persones caucàsiques.

- **Biaix d'edat:** Les imatges mostren predominantment persones joves (18-35 anys), ja que són el públic principal d'aquestes tendències a xarxes socials. El model podria tenir dificultats classificant vestimenta en persones de major edat.

- **Biaix de fonts:** Totes les imatges provenen exclusivament de Pinterest, una plataforma amb un estil visual particular (imatges curades, alta qualitat, bona il·luminació). Això pot limitar la capacitat de generalització del model a imatges de contextos més quotidians o d'altres plataformes com Instagram o TikTok.

5.3 Propostes de Millora

Per millorar el rendiment del model es proposen les següents accions:

Augmentar el nombre d'imatges d'entrenament i diversificar les fonts de dades: Ampliar el dataset a un mínim de 150-200 imatges per classe permetria al model captar més variabilitat dins de cada estil. Incorporar imatges d'altres plataformes com Instagram, TikTok o fotografies quotidianes per reduir el biaix de Pinterest i millorar la generalització a contextos reals.

Equilibrar la distribució demogràfica:
Incloure més imatges d'homes i de persones de diferents edats i orígens ètnics per reduir els biaixos identificats.

Resoldre la confusió classes colindants:
Per la confusió entre CottageCore i Old Money, es podrien afegir més imatges que representin els casos límit.

6 Implementació de l'Aplicació

6.1 Descripció Tècnica

L'aplicació web s'ha desenvolupat utilitzant HTML, CSS i JavaScript amb la llibreria TensorFlow.js per carregar i executar el model exportat de Teachable Machine.

Característiques principals:

- Càrrega asíncrona del model
- Pujada d'imatges i suport per webcam
- Interfície responsive

6.2 Llindar de Confiança

El sistema només mostra un resultat de predicció si la probabilitat màxima supera el llindar θ:

$$y =_{y \in C} P(y|x) \quad \text{si} \quad \max(P(y|x)) > \theta \tag{1}$$

S'ha establert $\theta = 0.7$ (70%) com a llindar per defecte. Així i tot, a l'aplicació web s'ha decidit deixar els resultats dels percentatges en cas de que no es superi aquest llindar com a forma il·lustrativa del funcionament del model.

7 Conclusions

El model aconsegueix una accuracy del 98% sobre el conjunt de test, demostrant que les quatre classes definides tenen característiques visuals prou diferenciades per ser classificades automàticament. No obstant això, s'ha de tenir en compte que tant les imatges d'entrenament com les de test provenen de Pinterest, una plataforma amb un estil visual particular: imatges curades, bona il·luminació i alta qualitat. Per tant, el rendiment màxim del model s'obté amb imatges d'aquest tipus, i pot degradar-se amb fotografies més quotidianes o de menor qualitat.

Així doncs, encara que s'ha implementat el suport per webcam, aquesta funcionalitat es manté com a ús didàctic i demostratiu, ja que aquest tipus d'imatges més quotidianes no han estat incloses en l'entrenament del model. Els estils més fàcils de classificar són Streetwear i Rockstar, ja que presenten característiques visuals molt distintives (colors saturats i logos; cuir i tons foscos). En canvi, la confusió entre CottageCore i Old Money era previsible donada la similitud en paletes cromàtiques i l'absència d'elements diferenciadors quan les peces no presenten estampats.

Som conscients que existeixen molts més estils de moda i que la classificació pot tenir un component subjectiu, especialment en casos límit. Els principals reptes identificats són la dependència d'una única font de dades, els biaixos demogràfics del dataset i la sensibilitat a condicions d'il·luminació variables.

Malgrat aquestes limitacions, l'aplicació resultant és funcional i adequada per a demostracions interactives del potencial de les eines d'aprenentatge automàtic en el camp de la moda.